

SVEUČILIŠTE U SLAVONSKOM BRODU

Stručni prijediplomski studij Informatika i informacijske tehnologije

SEMINARSKI RAD

**AUTOMATSKO PREPOZNAVANJE
REGISTARSKIH OZNAKA – USPOREDBA
DETEKCIJE I OCR PRISTUPA**

Ime i Prezime

Leon Nikolas Kerdić

Slavonski Brod, 2026.

SVEUČILIŠTE U SLAVONSKOM BRODU

Stručni prijediplomski studij Informatika i informacijske tehnologije

SEMINARSKI RAD

**AUTOMATSKO PREPOZNAVANJE
REGISTARSKIH OZNAKA – USPOREDBA
DETEKCIJE I OCR PRISTUPA**

Kolegij: Računalni vid

Ime i Prezime: Leon Nikolas Kerdić

Nastavnik: dr. sc. Marija Habijan

Slavonski Brod, 2026.

SAŽETAK

Automatsko prepoznavanje registarskih oznaka (Automatic License Plate Recognition – ALPR) predstavlja važnu primjenu računalnog vida koja omogućuje automatsku identifikaciju vozila na temelju registarske oznake. Takvi sustavi koriste se u nadzoru prometa, kontroli pristupa, naplati cestarina te sustavima upravljanja prometom. U ovom radu prikazan je pregled osnovnih komponenti ALPR sustava, uključujući detekciju registarskih oznaka, segmentaciju znakova i optičko prepoznavanje znakova (OCR). Poseban naglasak stavljen je na usporedbu klasičnih OCR metoda i suvremenih pristupa temeljenih na dubokom učenju.

Ključne riječi: ALPR, računalni vid, OCR, YOLO, duboko učenje, detekcija objekata, registarske oznake

SADRŽAJ

1. UVOD.....	4
2. PREGLED PODRUČJA I PROBLEMATIKE.....	5
2.1. Automatsko prepoznavanje registarskih oznaka.....	5
2.2. Klasične metode detekcije registarskih oznaka.....	5
2.3. Detekcija registarskih oznaka korištenjem dubokog učenja.....	5
2.4. OCR Sustavi.....	6
2.5. Klasični OCR pristupi.....	6
2.6. OCR temeljen na dubokom učenju.....	6
2.7. Usporedba klasičnih OCR metoda i metoda temeljenih na dubokom učenju.....	7
3. IMPLEMENTACIJA SUSTAVA.....	8
4. METRIKE EVALUACIJE.....	9
4.1. Točnost prepoznavanja znakova (Character Accuracy).....	9
4.2. Točnost registarske oznake (Plate Accuracy).....	9
4.3. Preciznost i odziv detekcije.....	9
4.4. Robusnost sustava.....	9
5. REZULTATI.....	10
5.1. Korišteni skup podataka.....	10
5.2. Treniranje YOLO modela.....	10
5.3. Rezultati detekcije registarskih oznaka.....	11
5.4. Rezultati OCR sustava.....	14
6. ZAKLJUČAK.....	15
7. LITERATURA.....	16

1. UVOD

Automatsko prepoznavanje registarskih oznaka (Automatic License Plate Recognition – ALPR) predstavlja područje računalnog vida koje omogućuje identifikaciju vozila na temelju registarske oznake korištenjem digitalnih slika ili videozapisa. Takvi sustavi danas se koriste u naplati cestarina, kontroli pristupa, upravljanju prometom i sigurnosnim sustavima. ALPR sustavi postali su važan dio suvremenih inteligentnih transportnih sustava zbog mogućnosti automatske obrade velikog broja vozila bez ljudske intervencije [1].

Razvoj metoda dubokog učenja tijekom posljednjih godina značajno je unaprijedio uspješnost sustava računalnog vida. Tradicionalni pristupi temeljeni na ručno definiranim značajkama postupno su zamijenjeni neuronskim mrežama koje mogu automatski učiti relevantne značajke iz podataka [2].

Cilj ovog rada je prikazati osnovne komponente ALPR sustava, usporediti klasične OCR metode i moderne pristupe temeljene na dubokom učenju te opisati implementaciju sustava za automatsko prepoznavanje registarskih oznaka.

2. PREGLED PODRUČJA I PROBLEMATIKE

2.1. Automatsko prepoznavanje registarskih oznaka

Tipični ALPR sustav sastoji se od tri osnovne faze: detekcije registarske oznake, segmentacije znakova i optičkog prepoznavanja znakova (OCR) [1].

U prvoj fazi potrebno je pronaći položaj registarske oznake na slici vozila. Nakon toga slijedi izdvajanje pojedinačnih znakova ili cijelog područja registarske oznake. Posljednja faza pretvara sadržaj oznake u tekstualni zapis.

Ukupna kvaliteta sustava ovisi o uspješnosti svih navedenih koraka. Pogreška u detekciji često uzrokuje neuspjeh svih kasnijih faza obrade.

2.2. Klasične metode detekcije registarskih oznaka

Prije razvoja dubokog učenja detekcija registarskih oznaka uglavnom se temeljila na metodama obrade slike. Najčešće korišteni pristupi uključivali su detekciju rubova, morfološke operacije, analizu teksture te klasifikatore poput Haar Cascade algoritama [1].

Prednost takvih metoda bila je relativno mala računalna zahtjevnost, dok su glavni nedostaci uključivali osjetljivost na promjene osvjetljenja, kut snimanja i različite vrste registarskih oznaka.

2.3. Detekcija registarskih oznaka korištenjem dubokog učenja

Konvolucijske neuronske mreže predstavljaju temelj većine suvremenih sustava računalnog vida [2].

Danas se za detekciju registarskih oznaka najčešće koriste modeli poput Faster R-CNN, SSD i YOLO. Posebno se ističe YOLO (You Only Look Once) arhitektura koju su predstavili Redmon i suradnici [3].

Za razliku od tradicionalnih metoda koje problem detekcije rješavaju kroz više odvojenih koraka, YOLO istovremeno određuje položaj objekta i njegovu klasu. Takav pristup omogućuje vrlo brzo izvođenje te rad u stvarnom vremenu [3].

Brojna istraživanja pokazala su da YOLO modeli ostvaruju vrlo dobre rezultate u ALPR sustavima te predstavljaju jedno od najčešće korištenih rješenja za detekciju registarskih oznaka [7].

2.4. OCR Sustavi

OCR (Optical Character Recognition) predstavlja postupak pretvaranja teksta sa slike u strojno čitljiv oblik.

U ALPR sustavima OCR modul prima izdvojenu registarsku oznaku te pokušava prepoznati sadržaj svih znakova. OCR metode mogu se podijeliti na klasične pristupe i metode temeljene na dubokom učenju.

2.5. Klasični OCR pristupi

Klasični OCR sustavi obično zahtijevaju prethodnu segmentaciju znakova. Proces se sastoji od binarizacije slike, segmentacije znakova, ekstrakcije značajki te klasifikacije znakova.

Za klasifikaciju se često koriste metode poput Template Matchinga, k-NN algoritama i SVM klasifikatora [1].

Glavni nedostatak ovakvog pristupa je velika osjetljivost na šum, promjene fonta, refleksije svjetla i pogreške u segmentaciji.

2.6. OCR temeljen na dubokom učenju

Razvoj dubokog učenja omogućio je razvoj znatno preciznijih OCR sustava. Temelj modernih OCR rješenja čine konvolucijske neuronske mreže koje automatski uče značajke iz podataka [2].

Jedan od najpoznatijih pristupa predstavlja CRNN (Convolutional Recurrent Neural Network) arhitektura koju su predstavili Shi i suradnici [4]. CRNN kombinira konvolucijske slojeve za ekstrakciju značajki i rekurentne neuronske mreže za modeliranje slijeda znakova.

Prednost CRNN modela je mogućnost prepoznavanja cijelog teksta bez potrebe za zasebnom segmentacijom svakog znaka [4].

Novija istraživanja pokazala su da poboljšane CRNN arhitekture ostvaruju dodatna poboljšanja u točnosti prepoznavanja teksta u složenim uvjetima snimanja [5].

Suvremene CNN arhitekture često koriste i rezidualne mreže (ResNet) koje omogućuju treniranje vrlo dubokih modela uz očuvanje stabilnosti procesa učenja [6].

2.7. Usporedba klasičnih OCR metoda i metoda temeljenih na dubokom učenju

Klasične OCR metode imaju prednost jednostavne implementacije i manjih zahtjeva za računalnim resursima. Međutim, njihova uspješnost značajno opada u stvarnim uvjetima rada.

S druge strane, OCR sustavi temeljeni na dubokom učenju zahtijevaju veće količine podataka i računalne snage, ali ostvaruju veću točnost i otpornost na promjene osvjetljenja, kutova snimanja i šumova [4], [5].

Zbog toga su danas dominantan izbor u suvremenim ALPR sustavima.

3. IMPLEMENTACIJA SUSTAVA

Za praktični dio rada korišten je Kaggle ALPR Dataset koji sadrži ukupno 24 238 slika vozila. Skup podataka podijeljen je na 21 173 slike za učenje, 2 046 slika za validaciju i 1 019 slika za testiranje.

Za detekciju registarskih oznaka korišten je model YOLOv8n implementiran unutar biblioteke Ultralytics YOLO. Model je treniran na grafičkoj kartici NVIDIA GeForce GTX 1650 tijekom pet epoha uz veličinu ulazne slike od 640×640 piksela.

Nakon detekcije registarske oznake izdvojeno je područje oznake te je za prepoznavanje znakova korišten OCR sustav Tesseract OCR. Prije OCR obrade primijenjene su osnovne metode obrade slike poput pretvorbe u sivu skalu, povećanja rezolucije i binarizacije slike.

Postupak rada sustava sastoji se od sljedećih koraka:

1. Ulazna slika vozila
2. Detekcija registarske oznake korištenjem YOLOv8n modela
3. Izdvajanje područja registarske oznake
4. Predobrada slike za OCR
5. Prepoznavanje znakova korištenjem Tesseract OCR sustava
6. Generiranje tekstualnog zapisa registarske oznake

4. METRIKE EVALUACIJE

Za procjenu uspješnosti sustava korišteno je nekoliko standardnih metrika.

4.1. Točnost prepoznavanja znakova (Character Accuracy)

Predstavlja omjer broja ispravno prepoznatih znakova i ukupnog broja znakova.

4.2. Točnost registarske oznake (Plate Accuracy)

Predstavlja postotak registarskih oznaka koje su u potpunosti ispravno prepoznate.

4.3. Preciznost i odziv detekcije

Za procjenu kvalitete detekcije korišteno je:

- Precision,
- Recall,
- mean Average Precision (mAP).

Navedene metrike široko su prihvaćene u području detekcije objekata [1].

4.4. Robusnost sustava

Robusnost sustava procijenjena je analizom rada u različitim uvjetima:

- različito osvjetljenje,
- različite udaljenosti vozila,
- različiti kutovi snimanja,
- djelomična zaklanjanja registarske oznake.

5. REZULTATI

5.1. Korišteni skup podataka

Za potrebe praktičnog dijela rada korišten je Kaggle ALPR Dataset koji sadrži slike vozila s označenim registarskim oznakama. Dataset je organiziran u skladu s YOLO formatom te sadrži slike i pripadajuće anotacije koje definiraju položaj registarske oznake na slici.

Ukupan broj slika u datasetu iznosi 24 238. Od toga je 21 173 slika korišteno za treniranje modela, 2 046 slika za validaciju te 1 019 slika za završno testiranje sustava. Sve anotacije sadržavale su jednu klasu objekta nazvanu „license_plate“, odnosno registarska oznaka.

Velik broj dostupnih primjera omogućio je treniranje modela na različitim vrstama vozila, kutovima snimanja i uvjetima osvjetljenja, što pozitivno utječe na sposobnost generalizacije modela.

5.2. Treniranje YOLO modela

Za detekciju registarskih oznaka korišten je model YOLOv8n implementiran unutar biblioteke Ultralytics. Treniranje je provedeno na prijenosnom računalu opremljenom grafičkom karticom NVIDIA GeForce GTX 1650.

Prije glavnog treniranja provedena je jedna probna epoha s ciljem provjere ispravnosti dataseta, anotacija i konfiguracije modela. Nakon uspješno završenog probnog treniranja provedeno je treniranje modela tijekom pet epoha pri rezoluciji ulazne slike od 640×640 piksela.

Tijekom treniranja korišten je skup za učenje, dok je uspješnost modela procjenjivana na zasebnom validacijskom skupu. Nakon svake epohe računane su metrike Precision, Recall i mAP kako bi se pratilo napredovanje modela tijekom procesa učenja.

5.3. Rezultati detekcije registarskih oznaka

Nakon završetka treniranja modela ostvareni su vrlo dobri rezultati detekcije registarskih oznaka. Tijekom probnog treniranja koje je trajalo jednu epohu ostvarene su vrijednosti Precision = 95.6 %, Recall = 87.9 % i mAP50 = 92.9 %.

Nakon pet epoha treniranja rezultati su dodatno poboljšani te su ostvarene sljedeće vrijednosti:

- Precision = 97.6 %
- Recall = 94.6 %
- mAP50 = 97.0 %
- mAP50-95 = 65.3 %

Usporedba rezultata nakon prve i pete epohe pokazuje da je model uspješno učio tijekom procesa treniranja. Vrijednost mAP50 povećala se s 92.9 % na 97.0 %, dok je Recall povećan s 87.9 % na 94.6 %.



Figure 1: Slika 1. Primjer uspješne detekcije registarske oznake korištenjem modela YOLOv8n.

Na slici 1 prikazan je primjer uspješne detekcije registarske oznake korištenjem istreniranog modela. Model je ispravno odredio položaj registarske oznake te joj dodijelio visoku razinu pouzdanosti detekcije.

Metrika	1 epoha	5 epoha
Precision	95.6 %	97.6 %
Recall	87.9 %	94.6 %
mAP50	92.9 %	97.0 %
mAP50-95	56.7 %	65.3 %




Figure 2: Slika 2. Promjena funkcije gubitka i evaluacijskih metrika tijekom treniranja modela.

5.4. Rezultati OCR sustava

Za prepoznavanje znakova korišten je Tesseract OCR sustav. Nakon detekcije registarske oznake pomoću YOLO modela izdvojeno je područje oznake te je provedena dodatna obrada slike koja je uključivala pretvorbu u sivu skalu, povećanje rezolucije i binarizaciju.

Na testnom primjeru OCR sustav prepoznao je tekst „6510206“, dok se na stvarnoj registarskoj oznaci nalazio tekst raspoređen u dva reda. Većina znakova uspješno je prepoznata, dok su pojedini znakovi i posebni znakovi poput crtice izgubljeni tijekom procesa prepoznavanja.

Dobiveni rezultat pokazuje da OCR sustavi mogu uspješno prepoznati sadržaj registarskih oznaka, ali su osjetljivi na kvalitetu slike, raspored znakova i prisutnost šuma. Upravo zbog toga OCR dio sustava predstavlja jedan od izazovnijih koraka u ALPR sustavima.



Figure 3: Slika 3. Primjer izdvojene i obrađene registarske oznake prije OCR prepoznavanja.

6. ZAKLJUČAK

Automatsko prepoznavanje registarskih oznaka predstavlja jednu od važnijih primjena računalnog vida u suvremenim prometnim i sigurnosnim sustavima. U radu su prikazane osnovne komponente ALPR sustava, uključujući detekciju registarskih oznaka, segmentaciju područja od interesa te optičko prepoznavanje znakova.

U teorijskom dijelu rada analizirane su razlike između klasičnih OCR metoda i suvremenih pristupa temeljenih na dubokom učenju. Pokazano je da moderne metode ostvaruju znatno veću točnost i robusnost u stvarnim uvjetima rada, iako zahtijevaju veće računalne resurse i veću količinu podataka za treniranje.

U praktičnom dijelu rada implementiran je sustav za automatsko prepoznavanje registarskih oznaka korištenjem YOLOv8n modela za detekciju registarskih oznaka i Tesseract OCR sustava za prepoznavanje znakova. Model je treniran na Kaggle ALPR skupu podataka te je nakon pet epoha treniranja ostvario vrijednosti Precision = 97.6 %, Recall = 94.6 % i mAP50 = 97.0 %, što ukazuje na vrlo uspješnu detekciju registarskih oznaka.

Rezultati OCR sustava pokazali su da je moguće uspješno prepoznati sadržaj registarske oznake nakon njezina izdvajanja, pri čemu su uočena određena ograničenja povezana s kvalitetom slike, rasporedom znakova i prisutnošću šuma. Unatoč tome, dobiveni rezultati potvrđuju da kombinacija YOLO detekcije i OCR sustava predstavlja učinkovito rješenje za automatsko prepoznavanje registarskih oznaka.

Na temelju dobivenih rezultata može se zaključiti da ALPR sustavi imaju značajan potencijal primjene u području upravljanja prometom, kontrole pristupa i sigurnosnih sustava te predstavljaju važan smjer razvoja suvremenih sustava računalnog vida.

7. LITERATURA

- [1] S. Saha, A Review on Automatic License Plate Recognition System, 2019.
- [2] Y. LeCun, L. Bottou, Y. Bengio i P. Haffner, “Gradient-Based Learning Applied to Document Recognition,” *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [3] J. Redmon, S. Divvala, R. Girshick i A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [4] B. Shi, X. Bai i C. Yao, “An End-to-End Trainable Neural Network for Image-Based Sequence Recognition and Its Application to Scene Text Recognition,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 11, pp. 2298–2304, 2017.
- [5] W. Yu, M. Ibrayim i A. Hamdulla, “Scene Text Recognition Based on Improved CRNN,” *Information*, vol. 14, no. 7, 2023.
- [6] K. He, X. Zhang, S. Ren i J. Sun, “Deep Residual Learning for Image Recognition,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [7] R. Laroca et al., “An Efficient and Layout-Independent Automatic License Plate Recognition System Based on the YOLO Detector.”